

UNIVERSIDAD DE SONORA DIVISIÓN DE CIENCIAS EXACTAS Y NATURALES MAESTRÍA EN CIENCIA DE DATOS



Proyecto Final de Introducción a la Ciencia de Datos y sus Metodologías: Creación de base de datos y sus estructuras, conexión y análisis desde Jupyter Notebook.

Asignatura: Matemáticas para Ciencia de Datos

Profesor: Doctor Juan Pablo Soto Barrera

Alumna: María Elena Martínez Manzanares

Contenido

Descripción	3
Objetivos	3
Descripción de fuente de datos	4
Manejo de datos por medio de MySQL Workbench	5
4.1 Creación de base de datos	5
4.2 Creación de una vista	12
4.3 Creación de un procedimiento almacenado	14
4.4 Creación de una función	16
4.5 Conexión a la base de datos desde Jupyter Notebook	19
4.6 Análisis de consulta desde Jupyer Notebook	19
Repositorio con código de las consultas de Jupyter Notebook y base de datos	21
Referencias	22
	Descripción

1. Descripción

Actualmente, el uso de manejadores de base de datos es fundamental para la manipulación de datos debido a que posibilitan el uso de lenguaje de consulta SQL que permiten la identificación de datos que cumplen con características determinadas de una manera rápida. Debido a las diferentes necesidades presentadas en el manejo de la información, es común el uso de las vistas, procedimientos almacenados y funciones que nos permiten compartir, modificar y consultar información permitiendo diferentes niveles de accesibilidad y manipulación de la misma.

La flexibilidad de los manejadores de la base de datos y sus estructuras se extienden a la consulta, extracción y manipulación de datos desde un entorno de desarrollo integrado como lo son RStudio y Jupyter Notebook. Esto presenta el beneficio de acelerar los procesos de análisis de datos al exentarnos realizar la consulta directamente en el manejador de base de datos y posterior importación manual al entorno de desarrollo donde se está conduciendo el estudio de la información.

Por lo anterior, en el presente documento se describe el procedimiento llevado a cabo para la creación de una base de datos por medio del manejador MySQL Workbench, así también se muestra el procedimiento de la creación de una vista, un procedimiento almacenado y una función. Finalmente, se demuestra una conexión y consulta realizada a MySQL Workbench directamente desde un Jupyter Notebook.

2. Objetivos

- Crear una base de datos por medio de un manejador de base de datos.
- Realizar una conexión de la base de datos por medio de un Jupyter Notebook.
- Efectuar una consulta de la base de datos a través de Jupyter Notebook.
- Crear una vista, un procedimiento almacenado y una función en una base de datos.

3. Descripción de fuente de datos

Los análisis efectuados en este trabajo fueron realizados a partir de la base de datos Map of Migrant Mortality habilitado por el Arizona OpenGIS Initiative for Deceased Migrants (2013). Como esta tabla también fue utilizada para el proyecto final de la asignatura Ingeniería de Características, está disponible para su descarga en el repositorio presentado por Martínez, M. (2022). La tabla se compone de las columnas que se describen en la Tabla 1.

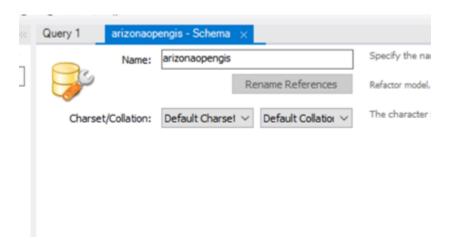
Tabla 1: Descripción de las características de la tabla MigrantMortality.

Variable	Tipo de etiqueta	Etiqueta	Descriptor de la variable	la variable Tipo de variable Unidades			
Name	Nominal	Nombre	Nombre de la persona ubicada sin vida	String			
Sex	Nominal	Sexo	Sexo de la persona ubicada sin vida	String (male/female)			
Age	Ordinal	Edad	Edad de la persona ubicada sin vida	Int	[0,∞)		
Reporting Date	Ordinal	Fecha de reporte	Fecha en que se reportó el avistamiento del cuerpo	Datetime	Año-mes- día		
Cause of Death	Nominal	Motivos de la muerte	Descripción breve de las causas de la muerte	String			
OME Determined COD	Nominal	Causa de la muerte determinada por el forense	Causa de la muerte (COD) determinada por el forense (Office of Medical Examiner / OME)	String			
Body Condition	Nominal	Condiciones del cuerpo	Nivel de putrefacción del cuerpo al ser encontrado	String			
Post Mortem Interval	Ordinal	Intervalo después de la muerte	Una estimación en meses del tiempo que llevaba la persona fallecida	String			
County	Nominal	Condado	Condado (equivalente a municipio) donde fue encontrado el cuerpo	String			

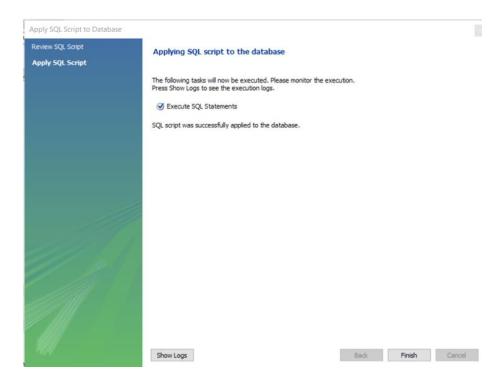
4. Manejo de datos por medio de MySQL Workbench

4.1 Creación de base de datos

Dentro de MySQL Workbench creamos una nueva base de datos la cual llamaremos 'arizonaopengis'.



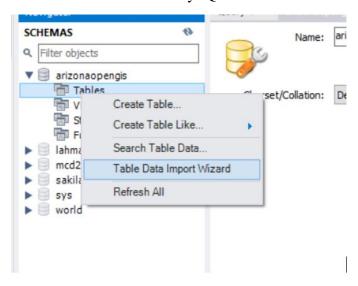
Esta ventana aparece una vez creada la base de datos, indicando que hemos acabado el proceso.



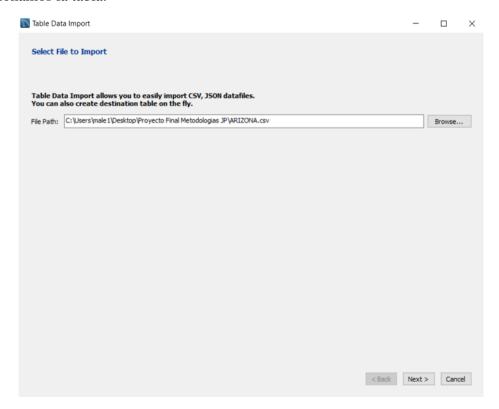
Podemos notar que la tabla de datos en la columna "Age" tiene datos faltantes. El wizard de MySQL para importar tablas desde archivos csv no maneja bien los datos faltantes y marcará con 0 (cero) a todos los datos faltantes. Es inconveniente importar y manipular los datos si fueron importados de esta manera ya que el valor cero en nuestra columna tiene interpretación al ser la edad de la persona fallecida. Aprovechando que es solamente una tabla y no tiene muchos registros, realizamos un data wrangling con Python en donde asignamos los nulos con el valor -1.

```
import pandas as pd
arizona=pd.read_csv("https://github.com/Maleniski/ing-
caracteristicas/raw/main/FuentesDatosMigrantes/ARIZONA.csv",index_col=
0)
arizona['Age'] = arizona['Age'].fillna(-1)
arizona.head(2)
arizona.to_csv("arizona.csv")
```

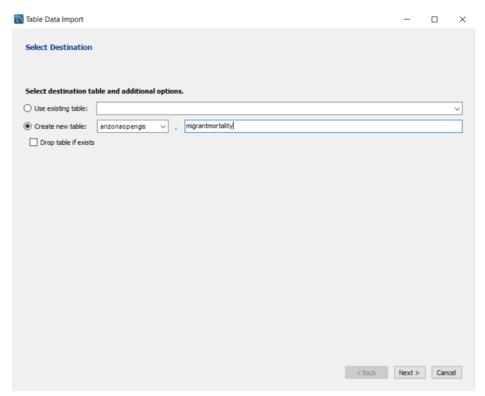
Procedemos a crear la tabla con el wizard de MySQL.



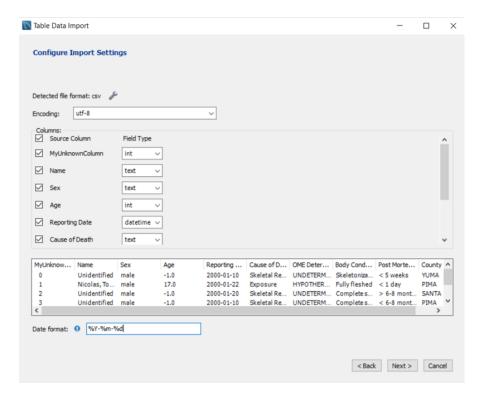
Seleccionamos la tabla.



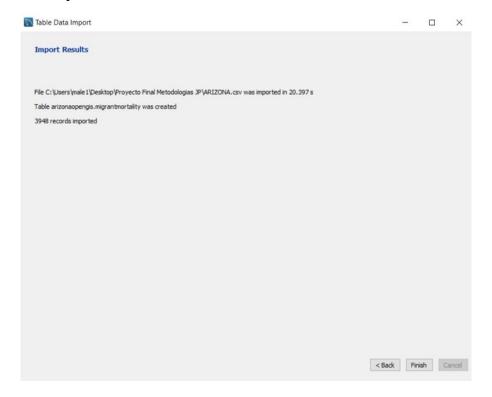
Asignamos el nombre "migrantmortality".



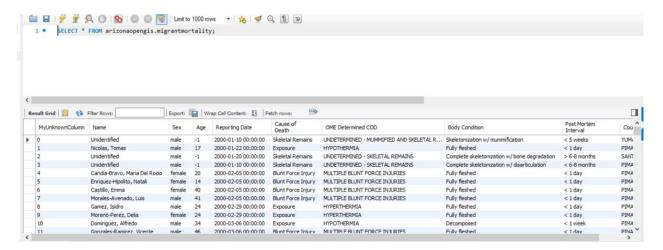
Indicamos de que tipo es la variable de cada columna y corregimos el date format dado que la columna "Reporting Date" es de tipo datetime.



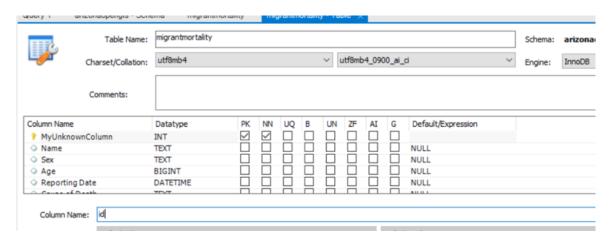
Finalizamos la importación.



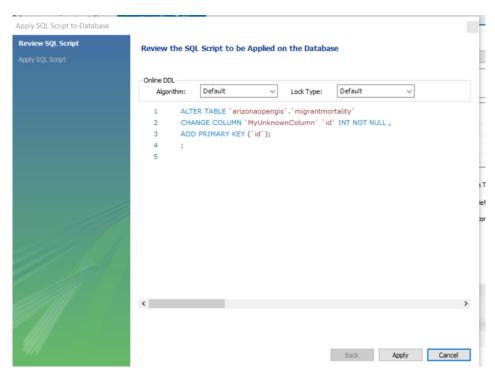
Podemos notar que el wizard no asignó bien el primary key (no da opción para marcarlo como tal durante el proceso de importación) y, además, la columna index la denominó "MyUnkownColumn".



Es necesario modificar esto. Utilizando la opción "Alter table", asignamos la columna "MyUnknownColumn" como el primary key (PK) y la renombramos a "id".



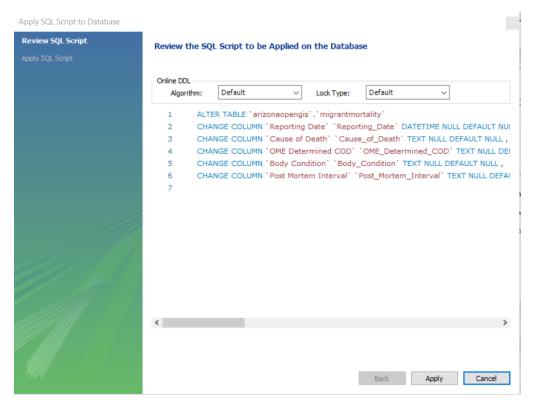
Completamos los cambios.



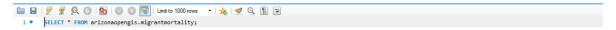
También, podemos notar que las columnas "Cause of Death", "OME Determined COD", "Body Condition", y "Post Mortem Interval" tienen espacios. Esto causa problemas al momento de realizar consultas. Utilizando la opción "Alter table" cambiamos los espacios por "_".

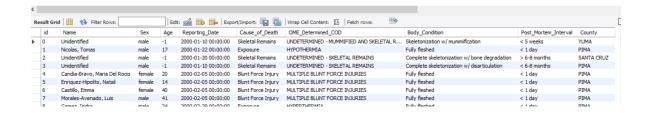
Datatype	PK	NN	UQ	В	UN	ZF	AI	G	Default/Expression
TEXT									NULL
TEXT									NULL
TEXT									NULL
TEXT									NULL
TEXT									NULL
	TEXT TEXT TEXT TEXT	TEXT							

Aplicamos los cambios.



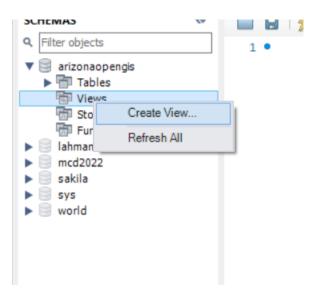
La tabla ya se encuentra en el formato correcto.



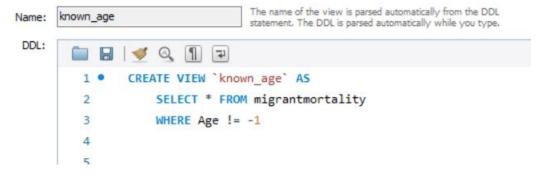


4.2 Creación de una vista

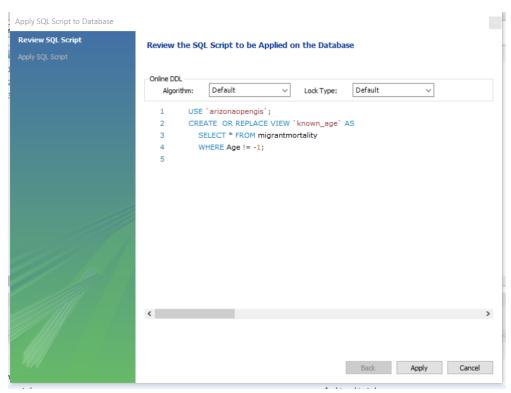
Supongamos que queremos una vista que solo nos muestre los registros con edad capturada. Esto lo podemos crear realizando una vista que excluya los registros con valor de la columna Age igual a -1. Creamos la vista.



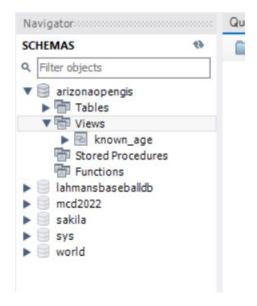
Por medio de esta consulta obtenemos los datos que estamos interesados.



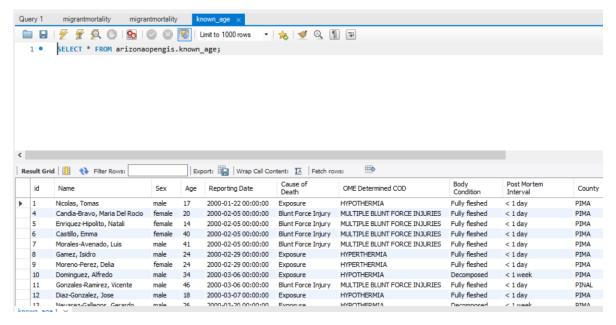
Aplicamos los cambios.



Podemos ver que la vista ya está disponible para su uso.

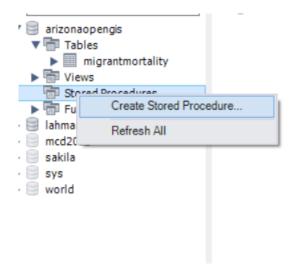


Es posible hacer uso de ella.



4.3 Creación de un procedimiento almacenado

Supongamos que de manera repetida estaremos realizando la consulta de migrantes localizados a partir de su género. Es en este escenario donde crear un stored procedure puede ser conveniente. Procedemos a crear entonces el Stored Procedure.



Definimos el stored procedure con las siguientes líneas de código.

```
CREATE PROCEDURE `selecciona_por_genero` (genero VARCHAR(30))

BEGIN

SELECT * FROM migrantmortality WHERE Sex = genero;

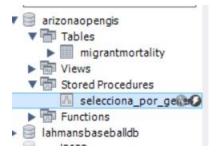
END

END
```

Aplicamos los cambios.



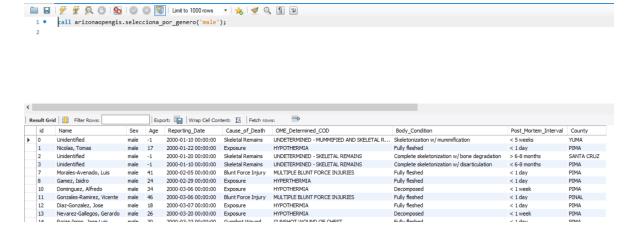
A partir de aquí, ya podemos hacer uso del stored procedure haciendo clic en el icono con dibujo de rayo.



Le solicitamos al stored procedure nos muestre los datos de los inmigrantes localizados que sean hombres.



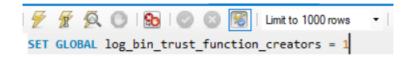
Obtenemos los siguientes resultados.



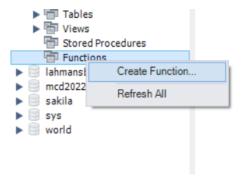
4.4 Creación de una función

Vamos a crear una función que nos permita introducir una causa de muerte por medio de una cadena de caracteres y nos regrese la cantidad de personas que han muerto por esa causa.

Antes de comenzar, es necesario correr la siguiente línea de código en la consola de SQL.



Procedemos a crear la función haciendo clic derecho en el apartado "Functions" de la base de datos.



Definimos la función.

```
TREATE FUNCTION `count_cause_death` (causa_muerte VARCHAR(50))

RETURNS INT

BEGIN

DECLARE cantidad_muertos integer;

SELECT COUNT(Cause_of_Death) INTO cantidad_muertos

FROM migrantmortality WHERE Cause_of_Death=causa_muerte;

RETURN cantidad_muertos;

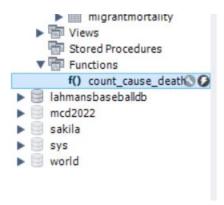
RETURN 1;

END
```

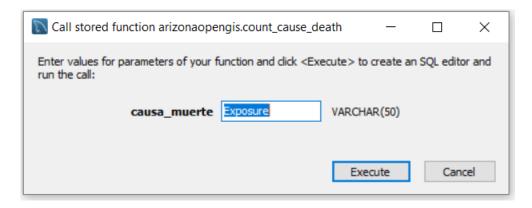
Aplicamos los cambios.



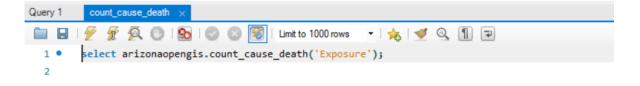
A partir de aquí, ya podemos hacer uso de la función haciendo clic en el icono con dibujo de rayo.

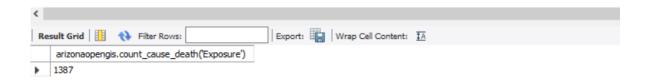


Le solicitamos a la función que nos indique el número de inmigrantes que han muerto por exposición.



Nos regresa la siguiente información.





4.5 Conexión a la base de datos desde Jupyter Notebook

Se importan las librerías necesarias.

```
import pymysql
import pandas as pd
import seaborn as sns
```

Creamos la conexión a la base de datos.

```
conn=pymysql.connect(host='XXX',port=int(3306),user='XXX',passwd='XXX',db='a
rizonaopengis')
```

Realizamos una consulta para corroborar que se realizó la conexión de manera correcta.

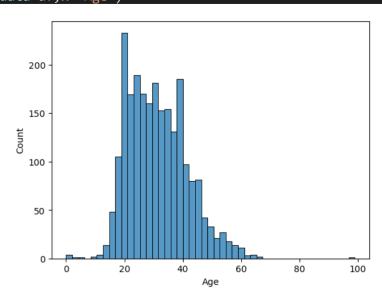
```
df=pd.read_sql_query("SELECT * FROM arizonaopengis.migrantmortality", conn,
index_col='id')
df.head(5)
```

Realizamos una consulta más específica. Las edades de la columna 'Age' con valores -1 de tabla 'migrantmortality' significa que el registro no contaba con valor de edad. Efectuamos una consulta de los registros que no tienen el valor -1.

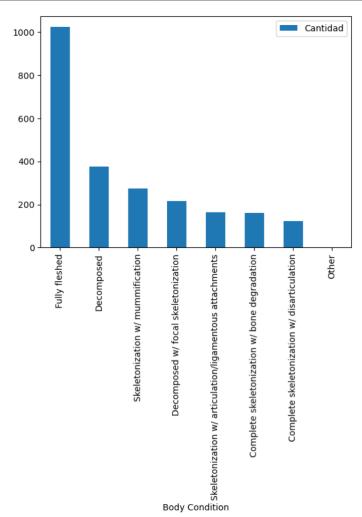
4.6 Análisis de consulta desde Jupyer Notebook

Hacemos un histograma de las edades.

sns.histplot(data=df,x="Age")



Finalmente, hacemos una gráfica de barras de la columna 'Body Condition'.



5. Repositorio con código de las consultas de Jupyter Notebook y base de datos

Las consultas realizadas por medio de Jupyter Notebook a su vez como el archivo que contiene la base de datos utilizado en este documento se dejan a disposición del lector para su revisión a través de la siguiente liga.

https://bit.ly/PF_MetodologiasBD_Manzanares

6. Referencias

- I. Arizona OpenGIS Initiative for Deceased Migrants. (2013). Web description. https://humaneborders.info/
- II. Martínez, M. (2 de noviembre del 2022). Repositorio con datos de Mortalidad de Migrantes. https://github.com/Maleniski/ing-caracteristicas/blob/main/FuentesDatosMigrantes/ARIZONA.csv